

# Métodos Iterativos: Gradientes Conjugados

## INF1608 – Análise Numérica

Departamento de Informática, PUC-Rio



# Reformulando o Problema

Sistema linear

$$A\mathbf{x} = \mathbf{b}$$

Exemplo:

$$\begin{bmatrix} 3 & 2 \\ 2 & 6 \end{bmatrix} \mathbf{b} = \begin{bmatrix} 2 \\ -8 \end{bmatrix}$$

► Solução:

$$\mathbf{x} = \begin{bmatrix} 2 \\ -2 \end{bmatrix}$$

- Interpretação geométrica
  - Interseção dos hiperplanos




Figura extraída de "An Introduction to the Conjugate Gradient Method Without the Agonizing Pain", Shewchuk, 1994

# Reformulando o Problema

## Forma Quadrática

- Equação escalar na forma:

$$f(\mathbf{x}) = \frac{1}{2}\mathbf{x}^T A \mathbf{x} - \mathbf{b}^T \mathbf{x} + c$$

- onde  $c$  é um valor escalar (p.e.  $c = 0$ )




Figura extraída de "An Introduction to the Conjugate Gradient Method Without the Agonizing Pain", Shewchuk, 1994

# Reformulando o Problema

Gradiente da forma quadrática (sendo  $A$  simétrica)

$$f'(\mathbf{x}) = A\mathbf{x} - \mathbf{b}$$

- ▶ Ponto mínimo de  $f(\mathbf{x})$ :

$$f'(\mathbf{x}) = 0 \rightarrow A\mathbf{x} = \mathbf{b}$$

- ▶ Sendo  $A$  positiva definida,  $f'(\mathbf{x}) = 0$  será sempre um **ponto de mínimo**, pois:

$$\mathbf{x}^T A \mathbf{x} > 0, \quad \forall \quad \mathbf{x} \neq \mathbf{0}$$

- ▶ Dessa forma, determinar solução de  $A\mathbf{x} = \mathbf{b}$  é equivalente a encontrar o ponto **mínimo** de  $f(\mathbf{x})$





# Reformulando o Problema

Gradiente da forma quadrática

$$f'(x) = Ax - b$$

Podemos achar o mínimo através do gradiente.





Figuras extraídas de "An Introduction to the Conjugate Gradient Method Without the Agonizing Pain", Shewchuk, 1994

# Determinação do Mínimo da Função

## Método *Steepest Descent* (Gradiente descendente)

- ▶ Tomar a direção inversa do gradiente
- ▶ Para cada passo:  $x_1 = x_0 + \alpha r_0$  (até um certo  $r_i < tol$ )
  - ▶ Lembrando que  $r_i = b - Ax_i$ , logo  $f'(x_i) = -r_i$
  - ▶ Qual o valor de  $\alpha$ ? (ponto em  $r_1^T r_0 = 0$ )



Figuras extraídas de "An Introduction to the Conjugate Gradient Method Without the Agonizing Pain", Shewchuk, 1994

# Método *Steepest Descent* (Gradiente descendente)

Algoritmo:

$$r_k = b - Ax_k$$

$$\alpha_k = \frac{r_k^T r_k}{r_k^T A r_k}$$

$$x_{k+1} = x_i + \alpha_k r_k$$

Pré-multiplicando  $x_{k+1}$  por  $-A$  e somando  $+b$ :

$$-Ax_{k+1} + b = -Ax_i - \alpha_k Ar_k + b$$

$$b - Ax_{k+1} = b - Ax_i - \alpha_k Ar_k$$


$$r_{k+1} = r_k - \alpha_k Ar_k$$

(calcula  $Ar_k$  apenas 1 vez para  $\alpha_k$  e  $r_{k+1}$ )



# Método *Steepest Descent* (Gradiente descendente)

Converge, mas resulta em muitas iterações Passos em direções repetidas







# Determinando mínimo em $n$ passos

E se soubermos o valor do erro?

- ▶ Desconsiderando o óbvio  $x_s = x_k - e_k$

Podemos zerar cada uma das  $n$  componentes utilizando um conjunto de vetores ortogonais ( $u_i^T u_j = 0$ )

- ▶ Remove todo o erro em uma direção
- ▶ Cobre todo o espaço de dimensão  $n$
- ▶ Erro zerado após  $n$  iterações



# Determinando mínimo em $n$ passos

Buscar as direções ortogonais  $\mathbf{d}_0, \mathbf{d}_1, \dots, \mathbf{d}_{n-1}$

- ▶ Erro expresso como combinação linear de  $\mathbf{d}'_k$ s
- ▶ Um passo em cada direção
  - ▶ Elimina cada componente do erro na direção  $\mathbf{d}_k$

Procedimento

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k$$

▶ Determinação de  $\alpha_k$

- ▶  $\mathbf{e}_{k+1}$  ortogonal a  $\mathbf{d}_k$

$$\mathbf{d}_k^T \mathbf{e}_{k+1} = 0$$

$$\mathbf{d}_k^T (\mathbf{e}_k + \alpha_k \mathbf{d}_k) = 0$$

$$\alpha_k = -\frac{\mathbf{d}_k^T \mathbf{e}_k}{\mathbf{d}_k^T \mathbf{d}_k}$$

▶ Mas não conhecemos  $\mathbf{e}_k$




Figura extraída de "An Introduction to the Conjugate Gradient Method Without the Agonizing Pain", Shewchuk, 1994

# Solução

Procurar vetores  $A$ -ortogonais, ou conjugados ( $d_i^T A d_j = 0$ )

- ▶  $d_k$  passa a ser  $A$ -ortogonal a  $e_{k+1}$ , e erro composto por  $d_k$ 's
  - ▶ i.e.  $e_0 = \sum_{j=0}^{n-1} \delta_j d_j$  e  $e_n = 0$
- ▶ Cada passo  $\delta_j d_j$  remove uma das componentes  $d_j$ 
  - ▶ Linearmente independentes para uma matriz SPD
  - ▶ Abrangem todo o espaço de dimensão  $n$




Figura extraída de "An Introduction to the Conjugate Gradient Method Without the Agonizing Pain", Shewchuk, 1994

## Exemplo [1]

$$\begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} x_0 \\ x_1 \end{bmatrix} = \begin{bmatrix} 10 \\ 8 \end{bmatrix}, \quad x_0 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \quad x_s = \begin{bmatrix} 4 \\ 2 \end{bmatrix}, \quad Ae_0 = \begin{bmatrix} -10 \\ -8 \end{bmatrix}$$

A partir das direções  $\begin{bmatrix} 1 \\ 1 \end{bmatrix}$  e  $\begin{bmatrix} 1 \\ -1 \end{bmatrix}$ :  $\begin{bmatrix} 1 \\ 1 \end{bmatrix}^T A \begin{bmatrix} 1 \\ -1 \end{bmatrix} = 0$

$$e_0 = -3 \begin{bmatrix} 1 \\ 1 \end{bmatrix} - 1 \begin{bmatrix} 1 \\ -1 \end{bmatrix}, \quad Ae_0 = -3A \begin{bmatrix} 1 \\ 1 \end{bmatrix} - 1A \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

$$x_s = \begin{bmatrix} 0 \\ 0 \end{bmatrix} + 3 \begin{bmatrix} 1 \\ 1 \end{bmatrix} + 1 \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

(Achar  $x_s$  é análogo a zerar o erro, mas qual o valor do erro?)



## Exemplo [2]

$$\begin{bmatrix} 3 & 2 \\ 2 & 6 \end{bmatrix} \begin{bmatrix} x_0 \\ x_1 \end{bmatrix} = \begin{bmatrix} 2 \\ -8 \end{bmatrix}, \quad x_s = \begin{bmatrix} 2 \\ -2 \end{bmatrix}, \quad Ae_0 = \begin{bmatrix} -2 \\ +8 \end{bmatrix}$$

A partir das direções  $\begin{bmatrix} 1 \\ 2 \end{bmatrix}$  e  $\begin{bmatrix} -2 \\ 1 \end{bmatrix}$ :  $\begin{bmatrix} 1 \\ 2 \end{bmatrix}^T A \begin{bmatrix} -2 \\ 1 \end{bmatrix} = 0$

$$e_0 = +0.4 \begin{bmatrix} 1 \\ 2 \end{bmatrix} + 1.2 \begin{bmatrix} -2 \\ 1 \end{bmatrix}, \quad Ae_0 = +0.4A \begin{bmatrix} 1 \\ 2 \end{bmatrix} + 1.2A \begin{bmatrix} -2 \\ 1 \end{bmatrix}$$

$$x_s = \begin{bmatrix} 0 \\ 0 \end{bmatrix} - 0.4 \begin{bmatrix} 1 \\ 2 \end{bmatrix} - 1.2 \begin{bmatrix} -2 \\ 1 \end{bmatrix}$$

(Achar  $x_s$  é análogo a zerar o erro, mas qual o valor do erro?)



# Erro transformado

Erro da solução

$$\mathbf{e}_k = \mathbf{x}_k - \mathbf{x}_s, \quad \mathbf{x}_s = \text{solução}$$

Resíduo

$$\mathbf{r}_k = \mathbf{b} - A\mathbf{x}_k$$

Substituindo  $\mathbf{x}_k$  no resíduo...

$$\mathbf{r}_k = \mathbf{b} - A(\mathbf{e}_k + \mathbf{x}_s), \quad (\mathbf{b} - A\mathbf{x}_s) = 0$$

$$\mathbf{r}_k = -A\mathbf{e}_k = -f'(\mathbf{x}), \quad \text{sabendo que } f'(\mathbf{x}) = A\mathbf{x} - \mathbf{b}$$

- ▶ O resíduo é o erro transformado por  $A$  no mesmo espaço de  $\mathbf{b}$
- ▶ Podemos zerar as componentes de  $r$  por direções  $A$ -ortogonais



# Método Gradiente Conjugado

Aplicado a uma matriz simétrica positiva definida

Dada uma estimativa inicial  $\mathbf{x}_0$ ...

- ▶ Elimina, um a um, as componentes do erro

Método direto *versus* iterativo:

- ▶ **Direto:** Solução exata após  $n$  iterações
- ▶ **Iterativo:** Parar antes de  $n$  iterações via tolerância numérica

Atualiza 3 vetores a cada iteração:

1. Vetor solução  $\mathbf{x}_k$
2. Vetor resíduo  $\mathbf{r}_k$ 
  - ▶ Sendo que  $A\mathbf{x}_{k+1} + \mathbf{r}_{k+1} = A\mathbf{x}_k + \mathbf{r}_k = \mathbf{b}$
3. Vetor direção  $\mathbf{d}_k$ , onde  $\mathbf{d}_{k+1}^T A \mathbf{d}_k = 0$ 
  - ▶ Atualiza  $\mathbf{x}_k$  para uma melhor solução  $\mathbf{x}_{k+1}$
  - ▶ Atualiza resíduo  $\mathbf{r}_k$  para  $\mathbf{r}_{k+1}$



# Método Gradiente Conjugado: Premissas/Propriedades

Direções de busca conjugadas em pares:  $\mathbf{d}_{k+1}^T \mathbf{A} \mathbf{d}_k = 0$

Direção de busca ortogonal ao resíduo

- ▶  $\mathbf{d}_k$  é  $A$ -ortogonal a  $\mathbf{e}_{k+1}$ :  $\mathbf{d}_k \perp \mathbf{A} \mathbf{e}_{k+1}$
- ▶  $\mathbf{d}_k$  é ortogonal a  $\mathbf{r}_{k+1} = -\mathbf{A} \mathbf{e}_{k+1}$ :  $\mathbf{d}_k \perp \mathbf{r}_{k+1}$
- ▶  $\mathbf{d}_k$  zera a componente de  $\mathbf{r}_k$ , na direção  $\mathbf{d}_k$

Ortogonalidade entre resíduos  $\mathbf{r}_{k+1} \perp \mathbf{r}_k$


- ▶ Passos são gerados para garantir essa propriedade
- ▶ Resíduo resultante  $\mathbf{r}_{k+1}$  não possui projeção ao longo de  $\mathbf{r}_k$





# Método Gradiente Conjugado: Exemplo de matriz 3x3

Conjugate Gradient in 3D (with Text Labels)



# Método Gradiente Conjugado

Atualização do vetor solução

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k$$

Atualização do vetor resíduo

- Sabe-se que:

$$A\mathbf{x}_{k+1} + \mathbf{r}_{k+1} = A\mathbf{x}_k + \mathbf{r}_k = b$$

- $r_{k+1}$  menor que  $r_k$ , e  $\mathbf{x}_{k+1}$  mais próximo da solução  $\mathbf{x}$
- Substituindo  $\mathbf{x}_{k+1}$ :

$$A(\mathbf{x}_k + \alpha_k \mathbf{d}_k) + \mathbf{r}_{k+1} = A\mathbf{x}_k + \mathbf{r}_k$$

$$A\mathbf{x}_k + \alpha_k A\mathbf{d}_k + \mathbf{r}_{k+1} = A\mathbf{x}_k + \mathbf{r}_k$$

$$\mathbf{r}_{k+1} = \mathbf{r}_k - \alpha_k A\mathbf{d}_k$$



# Método Gradiente Conjugado

Confirmando, vimos que o resíduo é o erro transformado por A:

$$\mathbf{r}_k = -A\mathbf{e}_k$$

E o erro é atualizado a partir de:

$$\mathbf{e}_{k+1} = \mathbf{e}_k + \alpha_k \mathbf{d}_k$$

Pré-multiplicando por  $-A$ :

$$-A\mathbf{e}_{k+1} = -A\mathbf{e}_k - \alpha_k A\mathbf{d}_k$$

$$\mathbf{r}_{k+1} = \mathbf{r}_k - \alpha_k A\mathbf{d}_k$$



# Método Gradiente Conjugado

Escolha de  $\alpha_k$

- ▶ Como  $\mathbf{d}_k$  deve ser ortogonal a  $\mathbf{r}_{k+1}$

$$\mathbf{d}_k^T \mathbf{r}_{k+1} = 0$$

- ▶ Como  $\mathbf{r}_{k+1} = \mathbf{r}_k - \alpha_k \mathbf{A} \mathbf{d}_k$ :

$$\mathbf{d}_k^T (\mathbf{r}_k - \alpha_k \mathbf{A} \mathbf{d}_k) = 0$$

$$\mathbf{d}_k^T \mathbf{r}_k = \alpha_k \mathbf{d}_k^T \mathbf{A} \mathbf{d}_k$$

$$\therefore \alpha_k = \frac{\mathbf{d}_k^T \mathbf{r}_k}{\mathbf{d}_k^T \mathbf{A} \mathbf{d}_k}$$



# Método Gradiente Conjugado

Escolha da nova direção de busca

- ▶ Resíduo é expresso por uma combinação linear de  $\mathbf{d}_k$ 's

$$\mathbf{d}_{k+1} = \mathbf{r}_{k+1} + \beta_k \mathbf{d}_k$$

- ▶ Partindo do requisito das direções serem conjugadas entre si

$$\mathbf{d}_{k+1} \mathbf{A} \mathbf{d}_k = 0$$

- ▶ Expandindo  $\mathbf{d}_{k+1}$ :

$$(\mathbf{r}_{k+1}^T + \beta_k \mathbf{d}_k^T) (\mathbf{A} \mathbf{d}_k) = \mathbf{r}_{k+1}^T \mathbf{A} \mathbf{d}_k + \beta_k \mathbf{d}_k^T \mathbf{A} \mathbf{d}_k = 0$$

$$\therefore \beta_k = - \frac{\mathbf{r}_{k+1}^T \mathbf{A} \mathbf{d}_k}{\mathbf{d}_k^T \mathbf{A} \mathbf{d}_k}$$



# Método Gradiente Conjugado: Algoritmo [1]

$\mathbf{x}_0$  = estimativa inicial

$\mathbf{d}_0 = \mathbf{r}_0 = \mathbf{b} - A\mathbf{x}$

**for**  $k = 0, 1, \dots, n - 1$  **do**

**if**  $\|\mathbf{r}_k\|_2 < tol$  **then**

**stop**

$$\alpha_k = \frac{\mathbf{d}_k^T \mathbf{r}_k}{\mathbf{d}_k^T A \mathbf{d}_k}$$

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k$$

$$\mathbf{r}_{k+1} = \mathbf{r}_k - \alpha_k A \mathbf{d}_k$$

$$\beta_k = -\frac{\mathbf{r}_{k+1}^T A \mathbf{d}_k}{\mathbf{d}_k^T A \mathbf{d}_k}$$

$$\mathbf{d}_{k+1} = \mathbf{r}_{k+1} + \beta_k \mathbf{d}_k$$



# Método Gradiente Conjugado

Forma alternativa de determinar  $\alpha_k = \frac{\mathbf{d}_k^T \mathbf{r}_k}{\mathbf{d}_k^T \mathbf{A} \mathbf{d}_k}$

- ▶ A partir da equação de  $\mathbf{d}_k$ :

$$\mathbf{d}_k = \mathbf{r}_k + \beta_{k-1} \mathbf{d}_{k-1}$$

- ▶ E  $\mathbf{d}_{k-1} \perp \mathbf{r}_k$ , podemos reescrever  $\mathbf{d}_k^T \mathbf{r}_k$ :

$$\mathbf{d}_k^T \mathbf{r}_k = (\mathbf{r}_k + \beta_{k-1} \mathbf{d}_{k-1})^T \mathbf{r}_k = \mathbf{r}_k^T \mathbf{r}_k + \beta_{k-1} \mathbf{d}_{k-1}^T \mathbf{r}_k = \mathbf{r}_k^T \mathbf{r}_k$$

- ▶ Assim,  $\alpha_k$  pode ser obtido por:

$$\alpha_k = \frac{\mathbf{r}_k^T \mathbf{r}_k}{\mathbf{d}_k^T \mathbf{A} \mathbf{d}_k}$$



# Método Gradiente Conjugado

Forma alternativa de determinar  $\beta_k = -\frac{\mathbf{r}_{k+1}^T \mathbf{Ad}_k}{\mathbf{d}_k^T \mathbf{Ad}_k}$

- A partir de:

$$\mathbf{r}_{k+1} = \mathbf{r}_k - \alpha_k \mathbf{Ad}_k \rightarrow \boxed{\mathbf{Ad}_k = \frac{\mathbf{r}_k - \mathbf{r}_{k+1}}{\alpha_k}}$$

$$\alpha_k = \frac{\mathbf{r}_k^T \mathbf{r}_k}{\mathbf{d}_k^T \mathbf{Ad}_k} \rightarrow \boxed{\mathbf{d}_k^T \mathbf{Ad}_k = \frac{\mathbf{r}_k^T \mathbf{r}_k}{\alpha_k}}$$

- Agora, substituindo em  $\beta_k$  e lembrando que  $\mathbf{r}_{k+1} \perp \mathbf{r}_k$ :

$$\beta_k = -\frac{-\mathbf{r}_{k+1}^T \frac{\mathbf{r}_k - \mathbf{r}_{k+1}}{\alpha_k}}{\frac{\mathbf{r}_k^T \mathbf{r}_k}{\alpha_k}} = -\frac{-\frac{\mathbf{r}_{k+1}^T \mathbf{r}_{k+1}}{\alpha_k}}{\frac{\mathbf{r}_k^T \mathbf{r}_k}{\alpha_k}} \rightarrow \boxed{\beta_k = \frac{\mathbf{r}_{k+1}^T \mathbf{r}_{k+1}}{\mathbf{r}_k^T \mathbf{r}_k}}$$





# Método Gradiente Conjugado: Algoritmo [2]

$\mathbf{x}_0$  = estimativa inicial

$\mathbf{d}_0 = \mathbf{r}_0 = \mathbf{b} - A\mathbf{x}$

**for**  $k = 0, 1, \dots, n - 1$  **do**

**if**  $\|\mathbf{r}_k\|_2 < tol$  **then**

**stop**

$$\alpha_k = \frac{\mathbf{r}_k^T \mathbf{r}_k}{\mathbf{d}_k^T A \mathbf{d}_k}$$

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k$$

$$\mathbf{r}_{k+1} = \mathbf{r}_k - \alpha_k A \mathbf{d}_k$$

$$\beta_k = \frac{\mathbf{r}_{k+1}^T \mathbf{r}_{k+1}}{\mathbf{r}_k^T \mathbf{r}_k}$$

$$\mathbf{d}_{k+1} = \mathbf{r}_{k+1} + \beta_k \mathbf{d}_k$$



# Método Gradiente Conjugado

Uso de preconditionadores

- ▶ Diminuir o número de condicionamento de  $A$
- ▶ Acelerar convergência

$$A\mathbf{x} = \mathbf{b}$$

$$M^{-1}A\mathbf{x} = M^{-1}\mathbf{b}$$

- ▶ onde  $M$  é o preconditionador

Escolha do preconditionador

- ▶ O mais próximo de  $A$  possível
  - ▶ Para  $M^{-1}A$  resultar numa matriz bem condicionada
- ▶ Fácil de inverter

Escolhas extremas

- ▶  $M = A$ , resultaria na identidade
- ▶  $M = I$ , teria inversa trivial



# Método Gradiente Conjugado: Algoritmo [3]

$x_0 =$  estimativa inicial

$r_0 = b - Ax$

$d_0 = z_0 = M^{-1}r_0$

**for**  $k = 0, 1, \dots, n - 1$  **do**

**if**  $\|r_k\|_2 < tol$  **then**

**stop**

$$\alpha_k = \frac{r_k^T z_k}{d_k^T A d_k}$$

$$x_{k+1} = x_k + \alpha_k d_k$$

$$r_{k+1} = r_k - \alpha_k A d_k$$

$$z_{k+1} = M^{-1} r_{k+1}$$

$$\beta_k = r_{k+1}^T z_{k+1} / r_k^T z_k$$

$$d_{k+1} = z_{k+1} + \beta_k d_k$$



# Método Gradiente Conjugado

Precondicionador de Jacobi

$$M = D$$

- ▶ Bom quando a matriz é estritamente diagonal dominante

Precondicionador simétrico sucessivo com sobrerelaxação  
(*Symmetrix Successive Over Relaxation* – SSOR)

$$M = (D + wL)D^{-1}(D + wU)$$

- ▶ com  $w \in [0, 2]$ 
  - ▶ Se  $w = 0$ , tem-se Jacobi
  - ▶ Se  $w = 1$ , tem-se Gauss-Seidel

Resolução de  $M\mathbf{z}_{k+1} = \mathbf{r}_{k+1}$  (ao invés de  $\mathbf{z}_{k+1} = M^{-1}\mathbf{r}_{k+1}$ )

- ▶ Precondicionador SSOR é um produto de matrizes triangulares

$$(I + wLD^{-1})(D + wU)$$



## Exercícios propostos

1. No Método Gradiente Conjugado, qual a importância do uso de pré-condicionadores? O pré-condicionador de Jacobi é dado por  $M = D$ ; em que situações ele é adequado?
2. Sabe-se que o Método Gradiente Conjugado garantidamente converge após  $n$  iterações. Como cada iteração tem complexidade  $O(n^2)$ , devido às operações de multiplicação de matriz por vetor, garante-se que o método chega a solução do sistema em  $O(n^3)$ . O método de Eliminação de Gauss também tem complexidade  $O(n^3)$ . Descreva um cenário onde o método Gradiente Conjugado apresenta ordem de complexidade linear ( $O(n)$ ).

